

DATA ANALYST / DATA SCIENCE PORTFOLIO

# Customer Churn Analysis & Prediction

Membangun sistem prediksi churn yang proaktif dari analisis data, machine learning, hingga dashboard & aplikasi siap pakai untuk perusahaan telekomunikasi.

**TRI HANDRA PURNA BHAKTI**

Sains Data, Universitas Brawijaya

# Profile



**TRI HANDRA PURAN BHAKTI**

Mahasiswa Sains Data  
Universitas Brawijaya

## Latar Belakang

Saya merupakan mahasiswa Sains Data Universitas Brawijaya yang memiliki ketertarikan pada bidang Data Analytics, Machine Learning, dan Business Intelligence. Saya telah mengikuti bootcamp Data Analyst & Data Science serta mengerjakan beberapa proyek analisis data, seperti customer churn prediction, dashboard interaktif, dan analisis logistik end-to-end. Selain itu, saya aktif mengembangkan kemampuan analisis data melalui pembelajaran mandiri dan kegiatan organisasi.

## Tech Stack yang Digunakan

Python

Pandas / NumPy

Scikit-learn

XGBoost

Optuna

Streamlit

Tableau

SMOTE / imblearn

# Mengapa Customer Churn Penting?




## Retensi Jauh Lebih Murah dari Akuisisi

Biaya menarik pelanggan baru jauh lebih besar dibanding biaya mempertahankan pelanggan lama. Karena itu, kemampuan mendeteksi risiko churn lebih awal jadi krusial bagi efisiensi budget dan keberlangsungan bisnis.




### Pendekatan Saat Ini Masih Reaktif

Tim retensi baru bertindak setelah pelanggan menunjukkan niat berhenti atau bahkan setelah benar-benar churn. Pendekatan ini mahal dan kurang efektif.



### Dampak ke Revenue Jangka Panjang

Churn yang tidak terdeteksi dini terakumulasi menjadi kehilangan revenue berulang, bukan cuma kehilangan satu kali transaksi.



### Peluang: Prediksi Proaktif

Dengan model prediksi churn, tim retensi bisa menargetkan pelanggan berisiko tinggi SEBELUM mereka berhenti retensi agar strategi terarah dan efisien.

# Goal & Flow Project

## Tujuan Project



### Deteksi Proaktif

Identifikasi pelanggan berisiko churn tinggi sebelum benar-benar berhenti.



### Pahami Faktor Utama

Memahami faktor-faktor yang paling memengaruhi keputusan pelanggan untuk churn.



### Rekomendasi Aksi

Menghasilkan rekomendasi bisnis yang bisa langsung ditindaklanjuti tim retensi/CRM.



### Siap Dipakai Tim Non-Teknis

Men-deploy model ke aplikasi Streamlit agar bisa dipakai memprediksi churn secara real-time.

## Alur Project (CRISP-DM based)



# Dataset & Business Questions

## IBM Telco Customer Churn Dataset

7,043

Baris Data  
(Pelanggan)

21

Kolom  
(Fitur + Target)

26.5%

Churn Rate  
(Class Imbalance)

Churn

Target Variable  
(Yes / No)

Data mencakup informasi demografis (gender, senior citizen, dependents), layanan yang digunakan (internet, phone, add-on), serta informasi kontrak & tagihan pelanggan sebuah perusahaan telekomunikasi.

### 20 Business Questions Terstruktur

Setiap tahap analisis (EDA hingga evaluasi model) dipandu oleh pertanyaan bisnis spesifik, supaya setiap insight langsung terhubung ke keputusan bisnis.

Lihat rincian lengkap 20 pertanyaan di lampiran notebook.

## Contoh Pertanyaan Kunci

- Q1


Berapa churn rate perusahaan secara keseluruhan?  
*Sebanyak 26,5% pelanggan (1.857 dari 7.043) mengalami churn, sedangkan 73,5% pelanggan (5.164) tetap bertahan. Hal ini menunjukkan bahwa dataset mengalami class imbalance, sehingga akan dilakukan penyeimbangan data menggunakan metode SMOTE pada tahap preprocessing.*
- Q8-10

Faktor kontrak, internet, dan metode pembayaran apa yang paling berpengaruh terhadap churn?  
*Jika diurutkan dari yang paling berpengaruh yaitu Contract, Internet Service, Payment Method, dan Add-on (Online Security, Tech Support, Paperless Billing).*
- Q16-17


Model mana yang paling baik memprediksi churn, dan fitur apa yang paling berpengaruh?  
*Model yang paling baik memprediksi yaitu Regresi Logistik dan fitur paling berpengaruh adalah Feature Importance.*
- Q19

Pelanggan mana yang harus diprioritaskan dalam program retensi?  
*Pelanggan yang harus diprioritaskan adalah pelanggan High Risk (probabilitas churn  $\geq 70\%$ ), terutama yang memiliki tenure pendek, kontrak Month-to-Month, dan MonthlyCharges tinggi.*


# EDA & Key Insights




26.5% pelanggan churn (1,869 dari 7,043) — dataset imbalance, ditangani dengan SMOTE.



Kontrak Month-to-Month adalah prediktor terkuat: churn rate jauh lebih tinggi dibanding One/Two Year.




Churn terkonsentrasi di bulan-bulan awal berlangganan — pelanggan baru paling berisiko.



Fiber Optic dan pembayaran Electronic Check punya churn rate tertinggi di kategorinya.

# Dashboard Tableau



## 4 KPI Card

Total Customer, Churn Rate, Avg Monthly Charges, Avg Tenure berada di ringkasan di atas.



## 9 Visualisasi Utama

Distribusi churn, kontrak, layanan internet, metode pembayaran, tenure, demografi, hingga charges.



## 5 Filter Interaktif

Gender, Contract, Internet Service, Payment Method, Senior Citizen di panel kiri.



## Alur Baca Terarah


KPI → seberapa besar churn → faktor layanan → perilaku pelanggan → demografi.



[Klik Disini](#)

# Machine Learning

## Preprocessing Pipeline



## Perbandingan 6 Model Klasifikasi

| Model              | Accuracy | Precision | Recall | F1-score | AUC-ROC |
|--------------------|----------|-----------|--------|----------|---------|
| k-NN               | 0.750    | 0.524     | 0.605  | 0.562    | 0.772   |
| Naive Bayes        | 0.759    | 0.534     | 0.696  | 0.604    | 0.825   |
| Decision Tree      | 0.710    | 0.456     | 0.503  | 0.478    | 0.644   |
| Regresi Logistik ★ | 0.789    | 0.601     | 0.602  | 0.601    | 0.840   |
| Random Forest      | 0.774    | 0.579     | 0.532  | 0.555    | 0.817   |
| XGBoost            | 0.764    | 0.556     | 0.532  | 0.544    | 0.815   |



### Kenapa Logistic Regression Dipilih Sebagai Model Final?

Bukan sekadar skor tertinggi — dipilih karena interpretability (koefisien mudah dibaca tim bisnis), performa kompetitif vs model ensemble, lebih ringan untuk retrain & deployment, serta lebih mudah diaudit untuk keputusan bisnis yang perlu dipertanggungjawabkan.

# Model Evaluation

78.6%

Accuracy

59.7%

Precision

59.7%



Recall

59.7%

F1-score

84.0%

AUC-ROC



Recall & AUC-ROC diprioritaskan dibanding Accuracy semata, karena biaya bisnis dari False Negative (pelanggan churn yang tak terdeteksi) jauh lebih mahal dibanding False Positive. Fitur dengan koefisien positif terbesar berkaitan dengan kontrak bulanan & Fiber Optic tanpa add-on; koefisien negatif terbesar berkaitan dengan tenure panjang & kontrak jangka panjang.

# Streamlit Deployment


## Aplikasi Multi-Halaman

- 

**Home**  
Ringkasan project & metrik model final
- 

**EDA & Visualisasi**  
Eksplorasi data interaktif
- 

**Perbandingan Model**  
Tabel & grafik metrik 6 model
- 

**Confusion Matrix**  
Evaluasi visual tiap model
- 

**Prediksi Churn**  
Form input → prediksi real-time
- 

**Tentang Aplikasi**  
Dataset, pipeline, tech stack

Telco Churn

Navigasi

Beranda

EDA dan Visualisasi

Perbandingan Model

Confusion Matrix

Prediksi Pelanggan

Tentang Aplikasi

Ringkasan Dataset

Total baris : 7,043

Total fitur : 20

Churn (Yes) : 1,869

No Churn : 5,174

Model Terbaik

Regresi Logistik

Perbandingan Model Klasifikasi

Enam model klasifikasi dilatih dan dievaluasi menggunakan dataset yang sama dengan SMOTE dan StandardScaler.

Tabel Metrik Semua Model

|   | Model            | Accuracy | Precision | Recall   | F1-score | AUC-ROC  | CV Mean F1 | CV Std F1 |
|---|------------------|----------|-----------|----------|----------|----------|------------|-----------|
| 0 | k-NN             | 0.750200 | 0.524500  | 0.604800 | 0.561800 | 0.772400 | 0.831400   | 0.007900  |
| 1 | Naive Bayes      | 0.758700 | 0.534000  | 0.606200 | 0.564400 | 0.825100 | 0.806800   | 0.012400  |
| 2 | Decision Tree    | 0.709600 | 0.456100  | 0.502700 | 0.478300 | 0.644200 | 0.804700   | 0.010400  |
| 3 | Regresi Logistik | 0.788600 | 0.600900  | 0.602200 | 0.601300 | 0.839700 | 0.847500   | 0.011800  |
| 4 | Random Forest    | 0.773700 | 0.578900  | 0.532300 | 0.554600 | 0.816700 | 0.851400   | 0.007700  |
| 5 | XGBoost          | 0.763700 | 0.556200  | 0.532300 | 0.544000 | 0.814800 | 0.849700   | 0.007300  |

Sel berwarna hijau menunjukkan nilai terbaik pada setiap metrik. Regresi Logistik dipilih sebagai model terbaik berdasarkan AUC-ROC tertinggi (0.8397).

Telco Churn

Navigasi

Beranda

EDA dan Visualisasi

Perbandingan Model

Confusion Matrix

Prediksi Pelanggan

Tentang Aplikasi

Ringkasan Dataset

Total baris : 7,043

Total fitur : 20

Churn (Yes) : 1,869

No Churn : 5,174

Model Terbaik

Regresi Logistik

Prediksi Churn Pelanggan

Masukkan data pelanggan untuk memprediksi apakah pelanggan akan berhenti atau tidak.

Informasi Demografi

Informasi Layanan

Informasi Kontrak dan Tagihan

Hasil Prediksi

CHURN

67.54%

Tidak Churn

32.46%

Probabilitas Prediksi

Churn

67.5%

Tidak Churn

32.5%

 URL Publik: [telco-churn-analysis-hywbx5cnhjzjqpyz4rexv.streamlit.app](https://telco-churn-analysis-hywbx5cnhjzjqpyz4rexv.streamlit.app)

Customer Churn Analysis & Prediction

10

# Business Recommendation

| Key Finding                             | Rekomendasi                                                  |
|-----------------------------------------|--------------------------------------------------------------|
| Churn rate 26.5%                        | Investasi sistem prediksi churn proaktif terjustifikasi      |
| Month-to-Month churn tertinggi          | Insentif migrasi ke kontrak jangka panjang                   |
| Churn terkonsentrasi di bulan awal      | Perkuat program onboarding 3-6 bulan pertama                 |
| Fiber Optic churn rate tinggi           | Evaluasi ulang value proposition Fiber Optic                 |
| Electronic Check churn tertinggi        | Dorong migrasi ke pembayaran otomatis                        |
| Pelanggan High Risk (skor $\geq 70\%$ ) | Integrasikan skor risiko ke sistem CRM sebagai flag otomatis |



## Kesimpulan

Project ini berhasil membangun sistem prediksi churn end-to-end dari EDA berbasis 20 business question, model Logistic Regression dengan AUC-ROC 0.84, dashboard Tableau interaktif, hingga aplikasi Streamlit siap pakai tim non-teknis. Rekomendasi di atas sebaiknya divalidasi lebih lanjut lewat A/B testing sebelum diterapkan secara penuh.

# Terima Kasih

Pertanyaan & Diskusi



[tpurnabhakti@gmail.com](mailto:tpurnabhakti@gmail.com)



[linkedin.com/in/triandra](https://www.linkedin.com/in/triandra)



[github.com/handra123](https://github.com/handra123)